AIoT HW2 — Claude 對話紀錄（節錄）

工具：Claude（Anthropic），透過 VS Code 的 Claude Code 擴充功能使用 · 紀錄時間至 2026-10-27 13:46
由 Claude Code 對話紀錄檔自動轉出之**節錄版**：保留與資料分析、建模、部署相關的 7 段專業討論，內容逐字保留未改寫；行政與操作性對話（檔案上傳步驟、版面配色等）整段省略，訊息內部分刪除處標示「（略）」；另省略工具執行過程與模型內部推理。

使用者

這是作業需求（略）。主題部分我想要使用各國平均壽命(WHO)，使用vercel部屬，github我可以自己上傳

[附件：PDF 文件]

Claude

找到 Kaggle 原始檔的 GitHub 鏡像（333,442 bytes，和 Kaggle 原檔大小一致），先下載下來：

資料下載好了：WHO 資料集共 2,938 筆、22 欄。我先快速看一下缺失值和分布，用來決定前處理方式：

使用者

你是使用有20個特徵的那個資料庫嗎

Claude

（此段回覆紀錄檔未保存，依對話畫面補錄）

對，我用的是 Kaggle 上的 **Life Expectancy (WHO)**（kumarajarshi）（略）。這份資料共 22 欄：

- 1 欄目標：`Life expectancy`
- 1 欄國名 `Country`：只當識別碼，用來依國家切分資料，不放進模型
- 其餘 **20 欄是特徵**：Year、Status（轉成 0/1）、Adult Mortality、HIV/AIDS、GDP、Schooling 等

20 個特徵大於 13，符合作業要求。接下來把 Notebook 轉檔並執行：

Notebook 執行成功。來看關鍵結果：

JS 的計算結果和 statsmodels 完全一致：係數、SE、p 值、CI/PI 都相同，CSV 解析也正確。接下來用 Edge 無頭模式截圖，確認網頁實際渲染的樣子：

兩個頁面都正常運作。發現一個版面問題：「係數」表格在雙欄排版中被截斷（p_cluster 欄看不到），修正一下：

所有數字都確認了。最後寫 README，它同時是作業報告。

README 完成。再截圖確認修正後的版面、Problem 2 頁面和手機寬度：

作業的程式、分析和網站都完成了，可以直接上傳 GitHub、部署到 Vercel。Notebook 已完整執行過；網站的回歸計算我用 Python 的 statsmodels 對過答案，係數、標準誤、p 值和信賴 / 預測區間都一致；頁面也實際截圖看過。

主要結果（Problem 1：預測平均壽命）

- 5 種特徵選擇方法比較後選出 8 個特徵。其中「五歲以下死亡數」和「嬰兒死亡數」幾乎是同一個資訊（VIF 約 198），剔除後剩 **7 個特徵**。
- 測試集是 37 個訓練時完全沒看過的國家，**R^2 為 0.811、誤差（RMSE）約 4.2 歲**。只用一個特徵的基準模型 R^2 是 0.534。
- 用全部 20 個特徵，R^2 可以到 0.845，但兩個死亡數特徵的係數互相抵消，無法解釋，所以部署的是 7 特徵版本。

- 95% 預測區間在測試集的實際覆蓋率是 91.2%，略低於 95%，原因寫在報告裡。
- 五大回歸假設只有「無多重共線性」通過，其餘四項都違反。最主要的原因是同一國家連續 16 年的資料彼此相關，所以改用以國家為群組的穩健標準誤來判斷顯著性。這些都如實寫在報告中。
- Problem 2（預測成人死亡率）的 R^2 只有約 0.42，因為這個欄位本身有明顯登錄錯誤，報告裡當作「資料品質影響」的對照來說明。

兩個加分項

- **下拉選單兩種 problem（+1）**：平均壽命、成人死亡率，各有完整的分析和互動預測。
- **任意輸入資料集（+2）**：下拉選單第 3 項，可以貼 CSV 網址（預設就是老師給的 50_Startups）或上傳檔案，並提供後向消去法和新樣本預測。

你還需要自己完成的部分

1. **上傳 GitHub**：資料夾整個推上去即可。
2. **Vercel 部署**：Add New Project → 匯入這個 repo → Framework Preset 選 **Other**，其他欄位留空 → Deploy。完成後把網址填進 README.md 第 3 行。
3. **NotebookLM 摘要**：這部分我無法代做。請用 NotebookLM 研究 Kaggle 上同主題的解法，把 100 字以上的摘要貼進 README 最後的【NotebookLM 摘要】段落。
4. **AI 對話紀錄 PDF**：匯出這段對話，存成 `notebooks/AI_conversation.pdf`。README 的【GPT 輔助內容】段落已經寫好，有標明使用的是 Claude Code，「本人確認 / 修改」那一欄請自己填。

在本機預覽網站時，要先執行 `python -m http.server`；直接雙擊 index.html 會讀不到模型檔。

主要檔案： - 報告：README.md - 分析：notebooks/HW2_Life_Expectancy_Regression.ipynb - 網站：index.html、app.js、style.css

使用者

特徵選擇為什麼是10個

Claude

特徵選擇的結果其實不是 10 個，而是 **7 個**。你看到的「10」應該是網頁上「各方法前 10 名排序」那張表。那張表只是**展示用**，把每種方法排序的前 10 名列出來方便比較，跟最後選幾個特徵無關。

實際的選擇過程是這樣：

1. **排序**：5 種方法（SelectKBest、RFE、SFS、Lasso path、Permutation）各自把 20 個特徵從重要到不重要排序。
2. **試 k = 1 ~ 20**：每種方法取前 k 個特徵，在訓練集上用「依國家分組的 5 折交叉驗證」算 RMSE，畫成網頁上那張折線圖。
3. **找最佳**：所有組合中 RMSE 最低的是 **SFS 取 11 個特徵**（RMSE 3.700）。
4. **精簡規則**：從圖上可以看到，k 大約到 8 之後曲線就幾乎平了，多加特徵改善很小。所以我設定「RMSE 不超過最佳值 1%（3.737 以內）時，選特徵數最少的組合」，結果是 **SFS 取 8 個**（RMSE 3.725，只差 0.7%）。
5. **VIF 共線性檢查**：這 8 個特徵中，「五歲以下死亡數」和「嬰兒死亡數」幾乎是同一個資訊（相關係數 0.997，VIF 198），所以剔除前者，**最後剩 7 個**。

最終的 7 個特徵是：收入組成（HDI）、HIV/AIDS、成人死亡率、小兒麻痺疫苗、嬰兒死亡數、白喉疫苗、B 肝疫苗。

為什麼不直接用 11 個？ 11 個的 CV RMSE 只比 8 個好 0.025 歲，幾乎沒差別。特徵越少，模型越好解釋，係數也越穩定。這是特徵選擇常見的取捨：在準確度差不多的情況下，選比較簡單的模型。

如果你覺得那張表容易讓人誤會，我可以把標題改成更清楚的說法，例如「各方法的特徵重要度排序（僅列前 10 名，最終選用 7 個）」。

使用者

部屬到vercel，有錯誤

[附圖]
[附圖]
[附圖]

Claude

原因是 Vercel 在 repo 裡看到 `requirements.txt`，就自動把專案當成 **Python 後端**，去找 `app.py`、`main.py` 這類進入點。我們的網站其實是純靜態網頁，根本不需要執行 Python。

修正方式是在 `vercel.json` 明確指定這是靜態網站，再加一個 `.vercelignore`，讓部署時直接忽略 Python 相關檔案：

我改了兩個檔案：

- vercel.json：加上 `"framework": null`（等同 Framework Preset 選「Other」），並把 build / install 指令設為空，告訴 Vercel 直接把資料夾當靜態網站。
- .vercelignore（新檔）：部署時排除 `requirements.txt`、`tools/`、`.py` 和 `.ipynb`。這些只是分析用的檔案，網站不需要它們，排除後 Vercel 就不會誤判成 Python 專案。

GitHub repo 本身不受影響，Notebook 等檔案都還在，只是 Vercel 部署時不會讀它們。

請照這三步處理：

1. **上傳到 GitHub**：進入你的 repo `susuannie/1028HW2` → **Add file → Upload files**，把 `vercel.json` 和 `.vercelignore` 兩個檔案拖進去，再按 **Commit changes**。同名的 `vercel.json` 會直接覆蓋。
2. **確認 Vercel 設定**：到 Vercel 專案的 **Settings → Build and Deployment**，確認 **Framework Preset** 是 **Other**。如果是 Python，請改成 Other 並儲存。
3. **重新部署**：GitHub commit 之後，Vercel 通常會自動重新部署。如果沒有，到 **Deployments** 點最新一筆右邊的 **⋯ → Redeploy**。

部署成功後，打開網址應該就能看到奶茶色的網頁。如果還有錯誤，把新的 Build Logs 截圖給我。

使用者

這些我們有做到嗎

[附圖]

Claude

這四項都有做到。下面逐項對照實際內容：

1. 使用線性回歸模型進行預測 ✅ - 核心模型是 OLS 多元線性回歸，sklearn 的 `LinearRegression` 和 statsmodels 的 `OLS` 都有用。 - 另外比較了 Ridge 和 Lasso，它們也是線性回歸，只是多了正則化。 - 網頁上可以選國家或拖曳滑桿，即時計算預測值。

2. 可嘗試單純線性回歸、多元線性回歸或 Auto Regression ✅ **（做了前兩種）**

類型	有沒有做	位置
單純線性回歸	✅	Baseline 模型：只用「收入組成」一個特徵，測試集 $R^2 = 0.534$
多元線性回歸	✅	主模型：7 個特徵，$R^2 = 0.811$；全 20 個特徵，$R^2 = 0.845$

類型	有沒有做	位置
Auto Regression	✕ 沒做	題目用的是「可嘗試」，屬於選做

模型比較表把單純線性回歸和多元線性回歸放在一起，直接看得出多元回歸好很多，正好呼應這一項。

3. 必須執行特徵選擇與模型評估 ✅ - **特徵選擇**：比較 5 種方法（SelectKBest、RFE、Sequential Feature Selection、Lasso path、Permutation importance），用交叉驗證評估 k = 1～20，再做 VIF 共線性檢查，最後從 20 個特徵選出 7 個。 - **模型評估**： - 測試集的 MAE、MSE、RMSE、R^2、Adjusted R^2 - 依國家分組的交叉驗證 - 5 個模型的比較表 - 五大回歸假設檢驗（線性、獨立性、同質變異、常態性、共線性）

4. 預測圖加上信賴區間或預測區間 ✅ - 兩種區間都有：95% 信賴區間（CI）和 95% 預測區間（PI）。 - Notebook 有靜態圖 assets/p1_prediction_intervals.png，網頁上有互動版預測區間圖，滑過每個點可以看到國家和區間。 - 另外還計算了 PI 的實際覆蓋率 91.2%，以及 10 國樣本的區間表。

關於 Auto Regression：題目寫的是「可嘗試」，沒做不會扣分。它主要用在時間序列，例如用過去幾年的壽命預測下一年。我們的資料是各國逐年資料，技術上可以做，但會偏離「用健康與社經指標預測壽命」這個主題，所以我不建議硬加。

使用者

資料集預測平均壽命方法摘要：

1. **資料前處理**：常以國家中位數或全域中位數填補缺失值，或直接剔除缺值過多之欄位；異常值主要採用**1.5×IQR 規則**或**極限截斷（Capping）**處理；對偏態嚴重之特徵（如 GDP、HIV/AIDS 及人口數）則進行 **Log 轉換**。
2. **模型與特徵選擇**：主要採用**線性回歸（Linear Regression）**與**隨機森林（Random Forest）**。特徵選擇則結合相關性矩陣（排除高度相關特徵 \\(|r| > 0.75\\)）、逐步前向選擇法（Forward Selection）及 P 值顯著性檢定 (\\(p \le 0.05\\))。
3. **重要特徵**：**受教育年限（Schooling）**與**收入資源組成（Income Composition / HDI）**是最關鍵的正向預測特徵，而**成人死亡率**與 **HIV/AIDS** 則是主要的負向特徵。
4. **模型表現**：線性回歸模型在測試集上的 \\(R^2\\) 大約落在 **0.85** 左右，RMSE 大約為 **3.57–3.63 年**。
5. **模型優缺點對比**：線性回歸**可解釋性高、結構簡單**，但較難自動捕捉非線性關係與複合特徵互動；隨機森林等非線性模型能有效處理複雜互動與異常值，**預測準確度與 \\(R^2\\) 通常更高**，但模型屬於灰黑盒，**可解釋性較低**。

Claude

摘要內容很完整，遠超過 100 字要求，五個面向都有回答到。我把它放進 README，只調整一個格式問題：`\\(R^2\\)` 這類 LaTeX 語法在 GitHub 上不會顯示成數學式，會直接出現反斜線，所以改成一般文字（R^2、$|r| > 0.75$、$p \le 0.05$），內容不動。

另外，我在摘要**下方**另外加一小段「與本作業比較」，明確標示這段是我們自己的分析，不屬於 NotebookLM 摘要。

我在比較表中寫了「教育年數與收入組成高度相關」，先用資料確認這個說法：

相關係數是 0.92，說法成立。我把數字補進表格，再重新產生報告 PDF：

NotebookLM 摘要已經放進 README 的【NotebookLM 摘要】段落，報告書 PDF 也重新產生了。

放進去的內容 - NotebookLM 摘要：內容照你貼的原文，只把顯示不出來的數學語法改成一般文字，例如 R^2、$|r| > 0.75$、$p \le 0.05$。開頭註明這是 NotebookLM 產生的摘要，符合老師「明確標示」的要求。 - **與本作業的比較**（另外加的，標示為「本人分析，非 NotebookLM 產生」）：把網路上常見的做法和我們的做法並排比較，並說明為什麼我們的 R^2 0.811 比網路上的 0.85 低。原因是我們依國家分組切分，測試的是模型沒看過的

國家，比隨機切分嚴格。這段可以當作報告的加分觀點。 - 比較表中「教育年數與收入組成高度相關」這句，我先用資料算過，相關係數是 0.92，再把數字補進表格。

你還需要補一個地方：摘要下方的「**參考來源**」目前寫著「⚠ 待補」。請填上你在 NotebookLM 實際加入的網址，因為我不知道你最後加了哪幾個。

更新後的剩餘項目 1. 填 NotebookLM 的參考來源網址 2. 修好 Vercel，把網址填進 README 第 3 行 3. 匯出對話 PDF，存成 `notebooks/AI_conversation.pdf` 4. 填 GPT 輔助內容表的「本人確認 / 修改」欄 5. 重新產生 PDF：`python tools/build_report.py --author "你的姓名 學號"` 6. 上傳 GitHub，到課程系統繳交

使用者

如果改做Spotify Tracks（歌曲熱門度）這個主題，會比較好嗎

Claude

我的建議是**不要換，維持 WHO 平均壽命**。主要有三個原因。

1. Spotify 熱門度很難用線性回歸預測

常見的 Spotify Tracks Dataset（Kaggle，約 11 萬首歌、20 欄）的特徵大多是音訊特性，例如舞曲性（danceability）、能量（energy）、音量（loudness）、節奏（tempo）。問題在於：

- **歌曲紅不紅，主要不是由音訊特性決定**，而是歌手知名度、行銷、發行時間、演算法推薦等，這些資料集裡都沒有。
- 我印象中，網路上用線性回歸預測這份資料的熱門度，R^2 通常很低，大約在 0.3 以下，只用音訊特徵時更低。實際數字要跑過才確定，但不太可能接近現在的 0.81。
- R^2 低，預測區間就會很寬。例如熱門度範圍 0～100，區間可能寬達 ±30 以上，預測圖會很不好看，也很難說明模型有用。
- 資料也有不少麻煩：同一首歌在不同曲風中重複出現；有大量熱門度為 0 的歌；曲風有 114 類，one-hot 之後特徵數會暴增。

2. WHO 很適合這份作業

	WHO 平均壽命	Spotify 熱門度
線性回歸表現	R^2 0.81（未見過的國家）	預期很低
係數好不好解釋	很好解釋，例如「HIV 越高壽命越低」	較難，例如舞曲性和熱門度的關係不明顯
預測區間	約 ±7 歲，有意義	預期非常寬
與網路解法比較	已完成 NotebookLM 研究	要重做

3. 截止日是明天

換主題的話，Notebook、模型、網站內容、README、資訊圖表、網頁截圖、報告 PDF 都要重做。我這邊技術上做得到，但你那邊的 **NotebookLM 研究也要重做**，GitHub 和 Vercel 也要重新整理，風險不小。目前你只剩部署和上傳，很接近完成了。

如果你只是對 Spotify 主題有興趣

不用換主題也能展示它，有兩種做法：

- **零修改**：繳交前在網站的「自訂資料集」貼上 Spotify CSV 網址，或直接上傳檔案，網站就會對它跑回歸。報告裡可以寫一句「本網站也可以分析其他資料集，例如 Spotify」。
- **改 Problem 2**：把目前的 Problem 2（成人死亡率）換成 Spotify 熱門度，當作「線性回歸在難預測的目標上表現有限」的對照。不過頁首寫的是 WHO 主題，兩個 problem 會變成不同資料集，整體會比較不一致，我不太推薦。

結論：維持 WHO，先把部署和繳交完成。如果你還是想換或想加 Spotify，告訴我是哪一種做法，我再評估要改哪些地方。