AIoT 物聯網數據分析與應用 · HW2 Multiple Linear Regression

# AIoT HW2：WHO 各國平均壽命預測 — 多元線性回歸（CRISP-DM）

報告日期：2026-10-27

- 🌐 **線上網站（Vercel）**：https://1028hw2-pearl.vercel.app/
- 💻 **GitHub**：https://github.com/susuannie/1028HW2
- 📓 **Notebook**：notebooks/HW2_Life_Expectancy_Regression.ipynb
- 📊 **資料集**：Life Expectancy (WHO) — Kaggle, KumarRajarshi
- 📄 **報告書 PDF**：notebooks/HW2_report.pdf

以 WHO 公開的各國健康與社經指標（193 國、2000–2015、2,938 筆、**20 個特徵**）進行多元線性回歸，依 CRISP-DM 完成資料理解、前處理、特徵選擇、建模、評估（含 95% 信賴 / 預測區間與五大回歸假設檢驗）到網頁部署。



## 加分項目對照

| 加分要求 | 實作 |
| --- | --- |
| ✅ 下拉選單呈現兩種 problem（+1） | 網頁頂端下拉選單：**Problem 1 預測平均壽命**、**Problem 2 預測成人死亡率**，兩者都有完整的特徵選擇、模型比較、區間圖、假設檢驗與互動預測 |
| ✅ 可任意輸入 Dataset（+2） | 下拉選單第 3 項「自訂資料集」：輸入 CSV 網址（預設 `50_Startups.csv`）或上傳檔案 → 自動判斷數值 / 類別欄位、one-hot、選目標與特徵、OLS、係數 t 檢定、95% CI / PI 預測圖、**後向消去法**、新樣本預測，全部在瀏覽器計算 |

## 網頁截圖

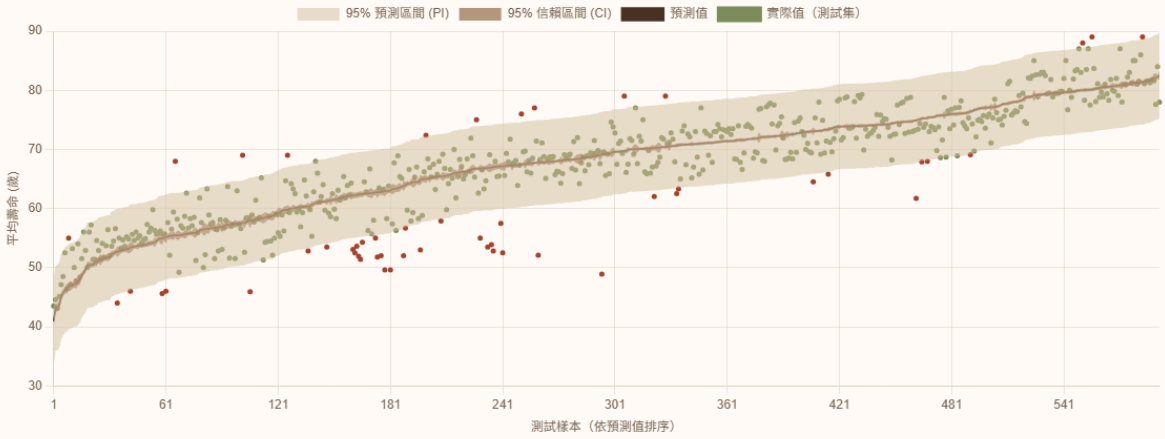
**Problem 1：KPI 與互動預測**（選國家帶入數值、拖曳滑桿，即時計算預測值與 95% CI / PI）




**預測圖與 95% 信賴 / 預測區間，以及測試集預測樣本表**

### 預測圖：95% 信賴區間與預測區間（測試集）

測試集為 37 個**完全沒出現在訓練集**的國家（592 筆）。焦糖色帶 = 平均值的信賴區間，奶茶色帶 = 單一觀測的預測區間；綠點 = 實際值，赤陶色點 = 落在 PI 外。 平均 CI 寬度 0.84、PI 寬度 14.36 歲。



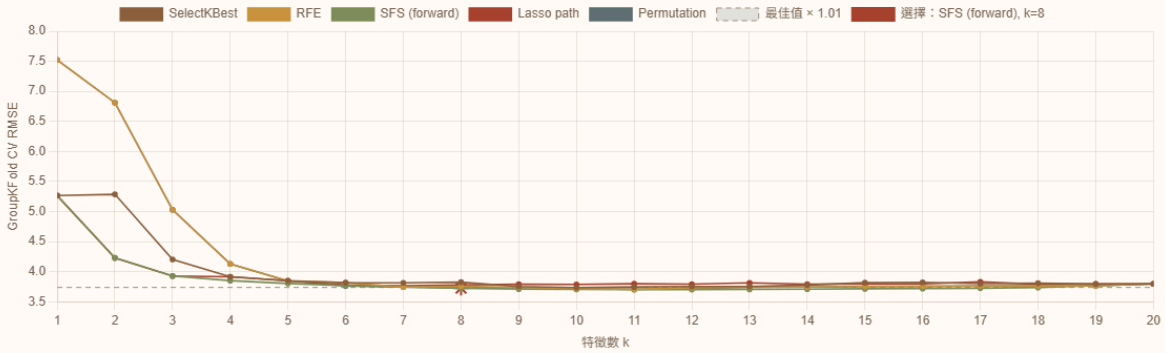

**測試集預測樣本（2015 年，依預測值平均抽取 10 國）**

| 國家 | 實際 | 預測 | 誤差 | 95% CI | 95% PI | 落在 PI 內 |
|---|---|---|---|---|---|---|
| South Sudan | 57.3 | 54.0 | +3.3 | [53.5, 54.4] | [46.8, 61.2] | ✓ |
| Guinea-Bissau | 58.9 | 58.0 | +0.9 | [57.7, 58.4] | [50.9, 65.2] | ✓ |
| Niger | 61.8 | 62.0 | -0.2 | [61.5, 62.5] | [54.8, 69.2] | ✓ |
| United Republic of Tanzania | 61.8 | 66.0 | -4.2 | [65.6, 66.5] | [58.8, 73.2] | ✓ |
| Solomon Islands | 69.2 | 68.2 | +1.0 | [67.8, 68.7] | [61.1, 75.4] | ✓ |
| El Salvador | 73.5 | 71.4 | +2.1 | [71.2, 71.6] | [64.2, 78.6] | ✓ |
| Belize | 71.0 | 73.0 | -2.0 | [72.7, 73.2] | [65.8, 80.1] | ✓ |
| Czechia | 78.8 | 74.7 | +4.1 | [74.4, 75.0] | [67.5, 81.9] | ✓ |
| Slovenia | 88.0 | 80.0 | +8.0 | [79.7, 80.3] | [72.8, 87.2] | ✗ |
| Norway | 81.8 | 81.9 | -0.1 | [81.5, 82.2] | [74.7, 89.0] | ✓ |

## 特徵選擇：5 種方法的 CV RMSE 曲線

### 特徵選擇（Feature Selection）

5 種方法各自產生特徵排序，以**訓練集** GroupKFold(5) 交叉驗證 RMSE 評估前 k 個特徵。 最佳為 SFS (forward) k=11（RMSE 3.700）；在「最佳值 × 1.01」內選最小 k → **SFS (forward)，k = 8**，再以 VIF > 10 剔除共線特徵。




**最終特徵**

人類發展指數-收入組成 (0–1) · HIV/AIDS 死亡 (每千活產, 0–4歲) · 成人死亡率 (每千人, 15–60歲) · 小兒麻痺疫苗覆蓋率 (%) · 嬰兒死亡數 (每千人口) · 白喉疫苗覆蓋率 (%) · B肝疫苗覆蓋率 (%) · ~~五歲以下死亡數 (每千人口) (VIF 198)~~

## Problem 2：成人死亡率（下拉選單切換）




**加分：自訂資料集**（預設載入 50_Startups.csv，自動 one-hot，提供後向消去法）

AIoT 物聯網數據分析與應用 • HW2 Multiple Linear Regression

# WHO 各國平均壽命 — 多元線性回歸

資料集：Life Expectancy (WHO) • Kaggle • 193 國 × 2000–2015 • 2,938 筆 • 20 個特徵 • 依 CRISP-DM 流程

選擇問題 ★ 自訂資料集：輸入任意 CSV（URL／上傳）

## 自訂資料集回歸

輸入 CSV 網址或上傳檔案，系統自動判斷數值／類別欄位（類別欄位做 one-hot，去掉第一個水準避免虛擬變數陷阱），在瀏覽器以 $\beta = (X^TX)^{-1}X^Ty$ 計算 OLS，並給出 95% 信賴區間與預測區間。網址需允許跨網域讀取（例如 raw.githubusercontent.com）。

https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv

載入網址

上傳 CSV | 範例：50_Startups | 範例：WHO Life Expectancy

已載入：50_Startups.csv（範例） — 50 筆 × 5 欄

| R&D Spend<br>數值 | Administration<br>數值 | Marketing Spend<br>數值 | State<br>類別 (one-hot) | Profit<br>數值 |
|---|---|---|---|---|
| 165349.2 | 136897.8 | 471784.1 | New York | 192261.83 |
| 162597.7 | 151377.59 | 443898.53 | California | 191792.06 |
| 153441.51 | 101145.55 | 407934.54 | Florida | 191050.39 |
| 144372.41 | 118671.85 | 383199.62 | New York | 182901.99 |
| 142107.34 | 91391.77 | 366168.42 | Florida | 166187.94 |

## 設定模型

目標變數 (y)

Profit

特徵 (X)

全選 | 全不選

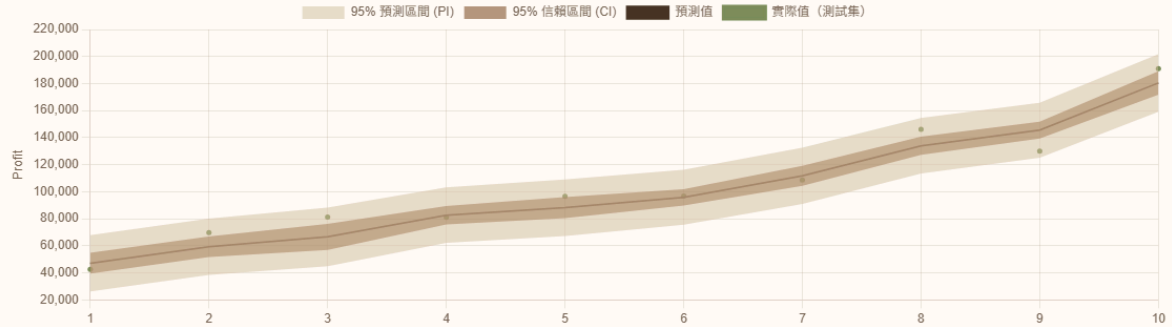
- [x] R&D Spend 數值
- [x] Administration 數值
- [x] Marketing Spend 數值
- [x] State 類別 • 3

測試集比例 0.2 隨機種子 42

執行回歸 | 後向消去法（p > 0.05）

| 訓練集 $R^2$ | 測試集 $R^2$ | 測試集 RMSE | 測試集 MSE | 95% PI 覆蓋率 |
|---|---|---|---|---|
| 0.951 | 0.942 | 9,668 | 93,470,948 | 100.0% |
| Adj $R^2$ 0.944 | Adj $R^2$ 0.870 | MAE 8,223 | n_train 40 / n_test 10 | $\sigma$ = 9,530 |

## 預測圖（測試集）：95% 信賴區間與預測區間



## 專案結構

```
├── index.html / style.css / app.js   # Vercel 靜態網站（Chart.js；OLS 與 t 分配在瀏覽器計算）
├── vercel.json
├── model/problem1.json, problem2.json # Notebook 匯出的最終模型、評估結果、圖表資料
├── notebooks/HW2_Life_Expectancy_Regression.ipynb
├── notebooks/HW2_report.pdf           # 報告書（由本 README 產生）
├── notebooks/Claude_conversation.pdf  # AI（Claude）對話紀錄
├── data/Life Expectancy Data.csv      # Kaggle 原始資料
├── data/50_Startups.csv               # 自訂資料集範例
├── assets/crisp_dm_infographic.png    # CRISP-DM 資訊圖表
├── assets/web_*.png                   # 網頁截圖
├── assets/*.png                       # Notebook 輸出圖表
├── tools/build_report.py              # README → 報告書 PDF
├── tools/export_conversation.py       # Claude Code 對話紀錄 → 對話 PDF
└── requirements.txt                   # Notebook 所需套件
```

---

## 1. Business Understanding

平均壽命是衡量國家健康與發展最常用的指標。本作業想回答：

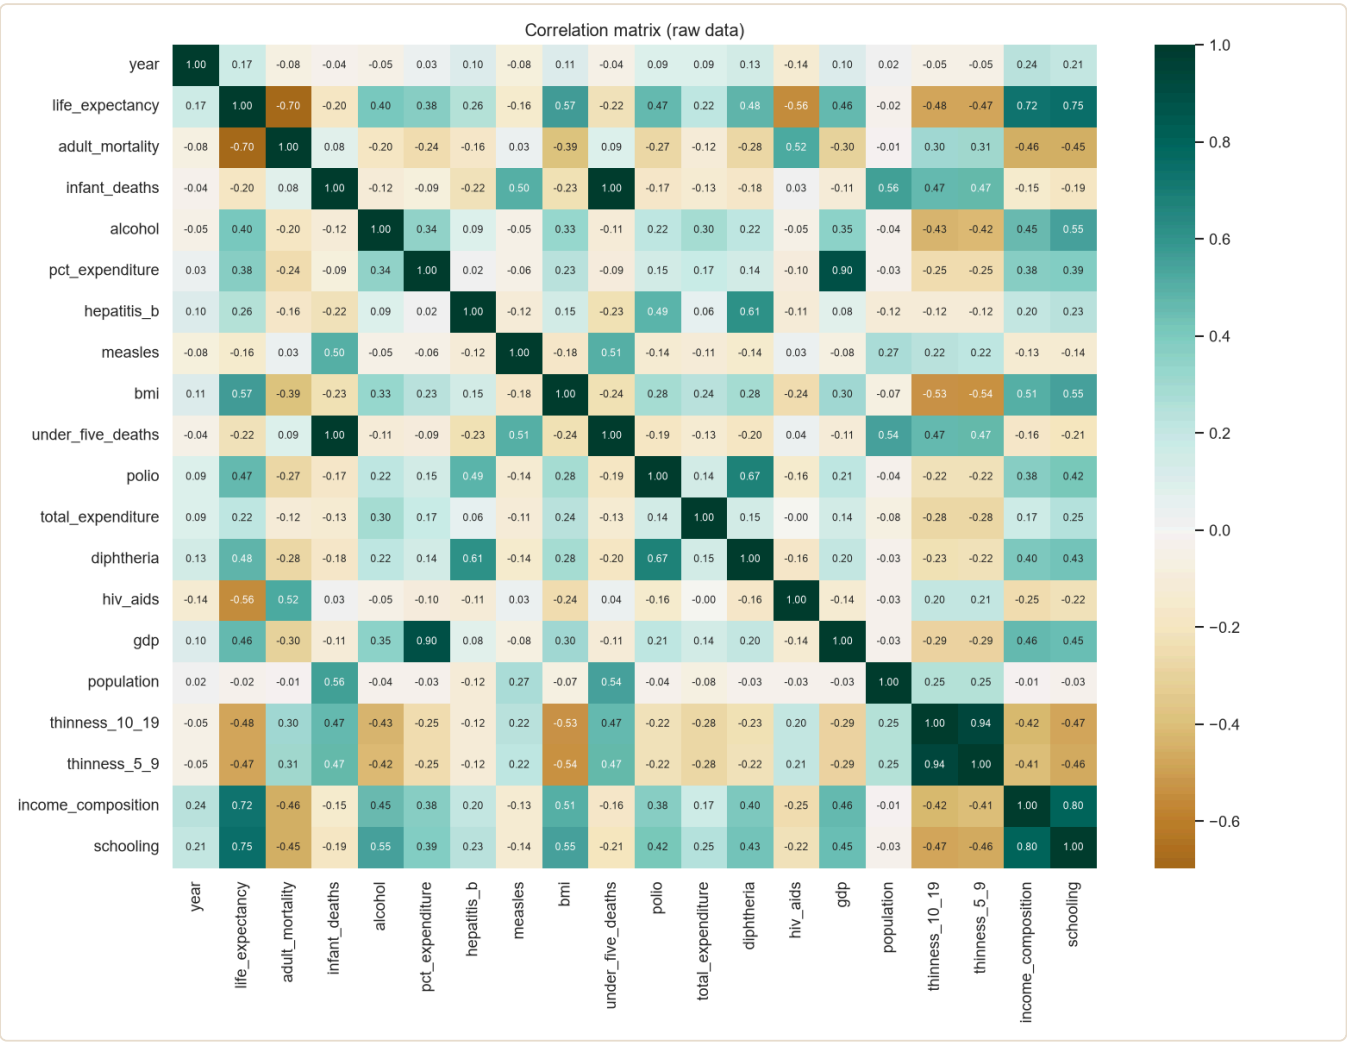
1. 哪些健康與社經因子與平均壽命關係最強？
2. 給定一國的指標，能否預測其平均壽命，並給出**不確定性範圍**？

| | Problem 1 | Problem 2 |
|---|---|---|
| 目標 y | 平均壽命（歲） | 成人死亡率（15–60 歲每千人死亡數） |
| 候選特徵 | 20 | 19（排除平均壽命，避免目標洩漏） |
| 成功標準 | 在「沒看過的國家」上 $R^2 \geq 0.80$ | 對照問題：觀察雜訊較大的目標 |

## 2. Data Understanding

- 2,938 筆 × 22 欄；扣除目標與 `Country`（識別碼）後 20 個特徵。
- 缺值最多：Population 22%、Hepatitis B 19%、GDP 15%。
- 與平均壽命相關最強：受教育年數 **+0.75**、收入組成（HDI）**+0.72**、成人死亡率 **−0.70**、HIV/AIDS **−0.56**。
- 高度共線的特徵：`infant_deaths` ↔ `under_five_deaths`（$r \approx 0.997$）、兩個消瘦率（0.94）、`pct_expenditure` ↔ `gdp`（0.90）。
- 資料品質問題：`income_composition`、`schooling` 有不合理的 0；`bmi` 有大量不合理值；多個欄位嚴重右偏（偏態 3 ~ 16）。




## 3. Data Preparation

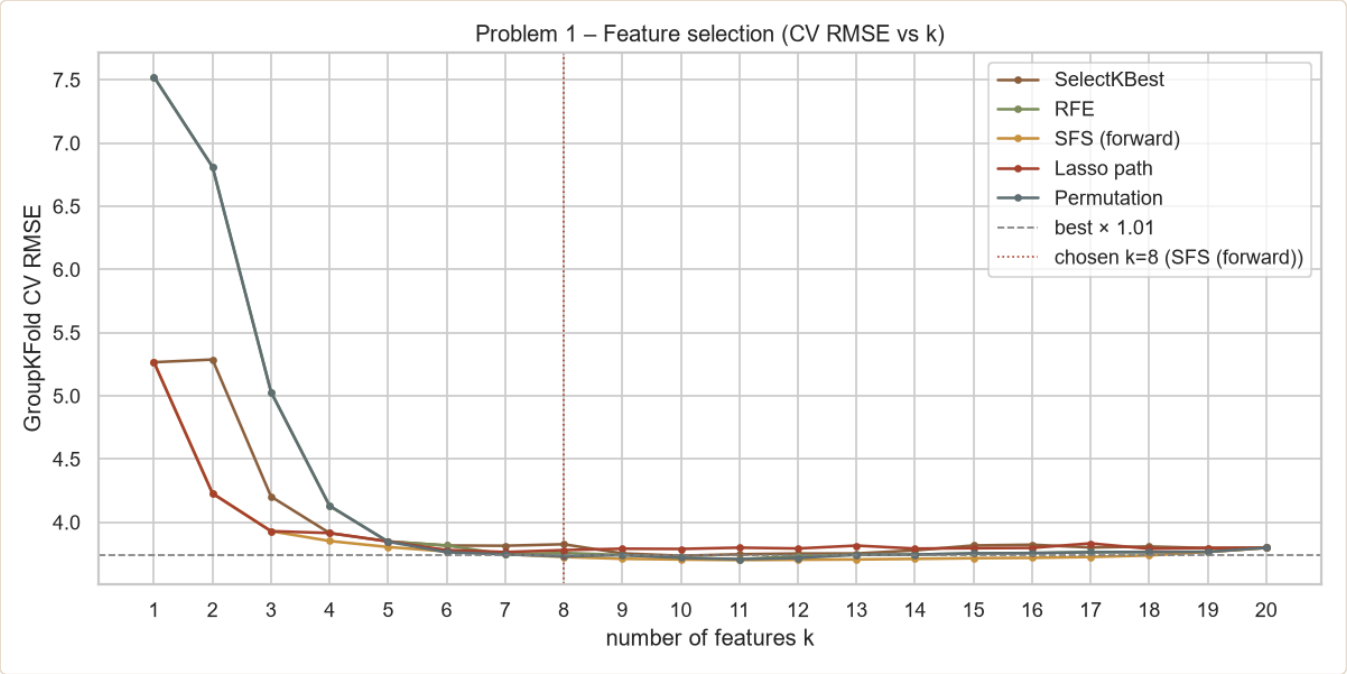
1. `Status` → `developed`（0/1）
2. `income_composition == 0`、`schooling == 0` → 缺值
3. 7 個右偏欄位（infant_deaths、pct_expenditure、measles、under_five_deaths、hiv_aids、gdp、population）做 `log1p`，例如 population 的偏態從 15.9 降到 −0.6
4. **以國家分組切分**（`GroupShuffleSplit`，80/20）：train 2,336 筆 / 146 國，test 592 筆 / 37 國，兩邊國家**零重疊**。這是 panel data，隨機切分會讓同一國家的其他年份洩漏到訓練集。
5. 缺值補訓練集中位數、標準化只在訓練集 fit（包在 Pipeline 中，CV 每一折各自 fit）

# 4. Modeling

## 4.1 特徵選擇（只用訓練資料）

5 種方法各產生一個特徵排序，再以 **GroupKFold(5) CV RMSE** 評估前 k 個特徵（k = 1…20）：

| 方法 | 類型 |
|---|---|
| SelectKBest (f_regression) | Filter |
| RFE (LinearRegression) | Wrapper |
| Sequential Feature Selection (forward) | Wrapper |
| Lasso path（進入順序） | Embedded |
| Permutation importance | Model-agnostic |




- 全域最佳：SFS k = 11，CV RMSE 3.700
- 規則：在「最佳值 × 1.01」內選最小 k → **SFS，k = 8**（也試過 1-SE rule，但分組 CV 標準誤大，只會留下 3 個特徵，測試集 $R^2$ 掉到 0.79）
- VIF 檢查：`under_five_deaths` VIF = **197.6**（與 infant_deaths 幾乎相同），剔除
- **最終 7 個特徵**：收入組成、HIV/AIDS、成人死亡率、小兒麻痺疫苗、嬰兒死亡數、白喉疫苗、B 肝疫苗

## 4.2 模型比較（Problem 1，測試集 = 37 個沒看過的國家）

| 模型 | k | Train $R^2$ | MAE | MSE | RMSE | $R^2$ | Adj $R^2$ |
|---|---|---|---|---|---|---|---|
| Baseline 簡單線性回歸（收入組成） | 1 | 0.693 | 4.68 | 43.53 | 6.60 | 0.534 | 0.533 |
| OLS – 全部特徵 | 20 | 0.862 | 2.88 | 14.47 | 3.80 | 0.845 | 0.840 |
| **OLS – 特徵選擇後** | **7** | **0.850** | **3.09** | **17.71** | **4.21** | **0.811** | **0.808** |
| RidgeCV – 全部特徵 | 20 | 0.862 | 2.88 | 14.46 | 3.80 | 0.845 | 0.840 |
| LassoCV – 全部特徵 | 20 | 0.862 | 2.85 | 14.31 | 3.78 | 0.847 | 0.841 |

**解讀**

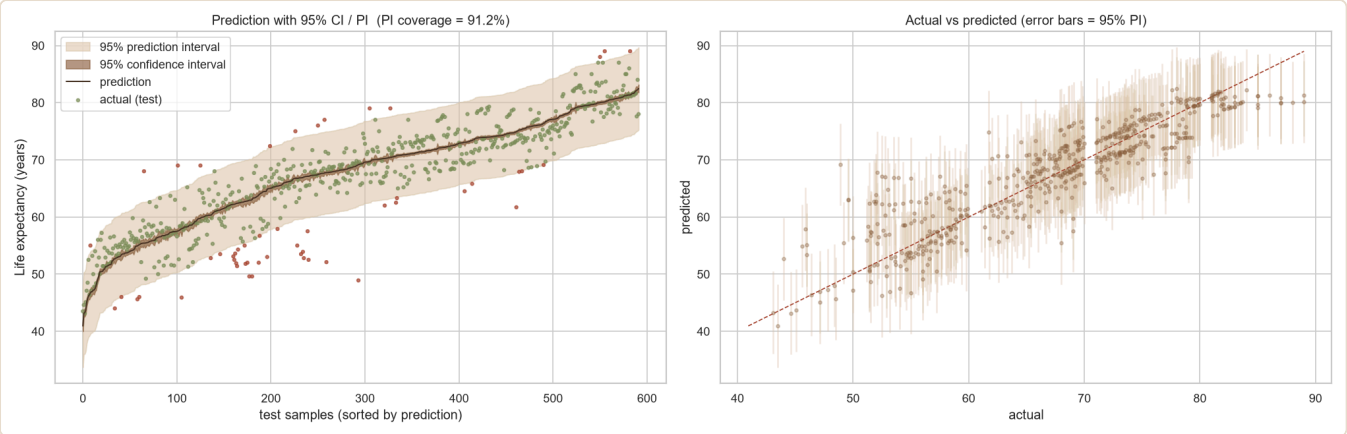
- 多元回歸比單一特徵 baseline 的 $R^2$ 高出約 0.28。
- 全特徵模型的 $R^2$ 多 0.03，但 `infant_deaths` 與 `under_five_deaths` 的標準化係數分別約 +7.2 和 −8.4，互相抵消（VIF 近 200），沒有解釋意義。
- 7 特徵模型的 VIF 全都 < 2.4，係數穩定、可以解釋，最後選它部署。
- Ridge / Lasso 與 OLS 幾乎相同，表示在此樣本量下過擬合不是主要問題。

## 4.3 最終係數（訓練集 OLS，cluster-robust p 值）

| 特徵 | 係數 | p_cluster | 解讀 |
|---|---|---|---|
| 收入組成 (0–1) | +26.93 | <0.001 | HDI 收入組成每 +0.1 → 壽命 +2.7 歲 |
| HIV/AIDS（log1p） | −3.41 | <0.001 | HIV 死亡率越高壽命越低 |
| 成人死亡率 | −0.0171 | <0.001 | 每千人多 100 人死亡 → −1.7 歲 |
| 小兒麻痺疫苗 (%) | +0.025 | 0.003 | |
| 嬰兒死亡數（log1p） | −0.61 | 0.005 | |
| 白喉疫苗 (%) | +0.037 | <0.001 | |
| B 肝疫苗 (%) | −0.024 | <0.001 | 符號為負：與另兩種疫苗高度相關，是控制其他疫苗後的「抑制效果」，不宜做因果解讀 |

# 5. Evaluation

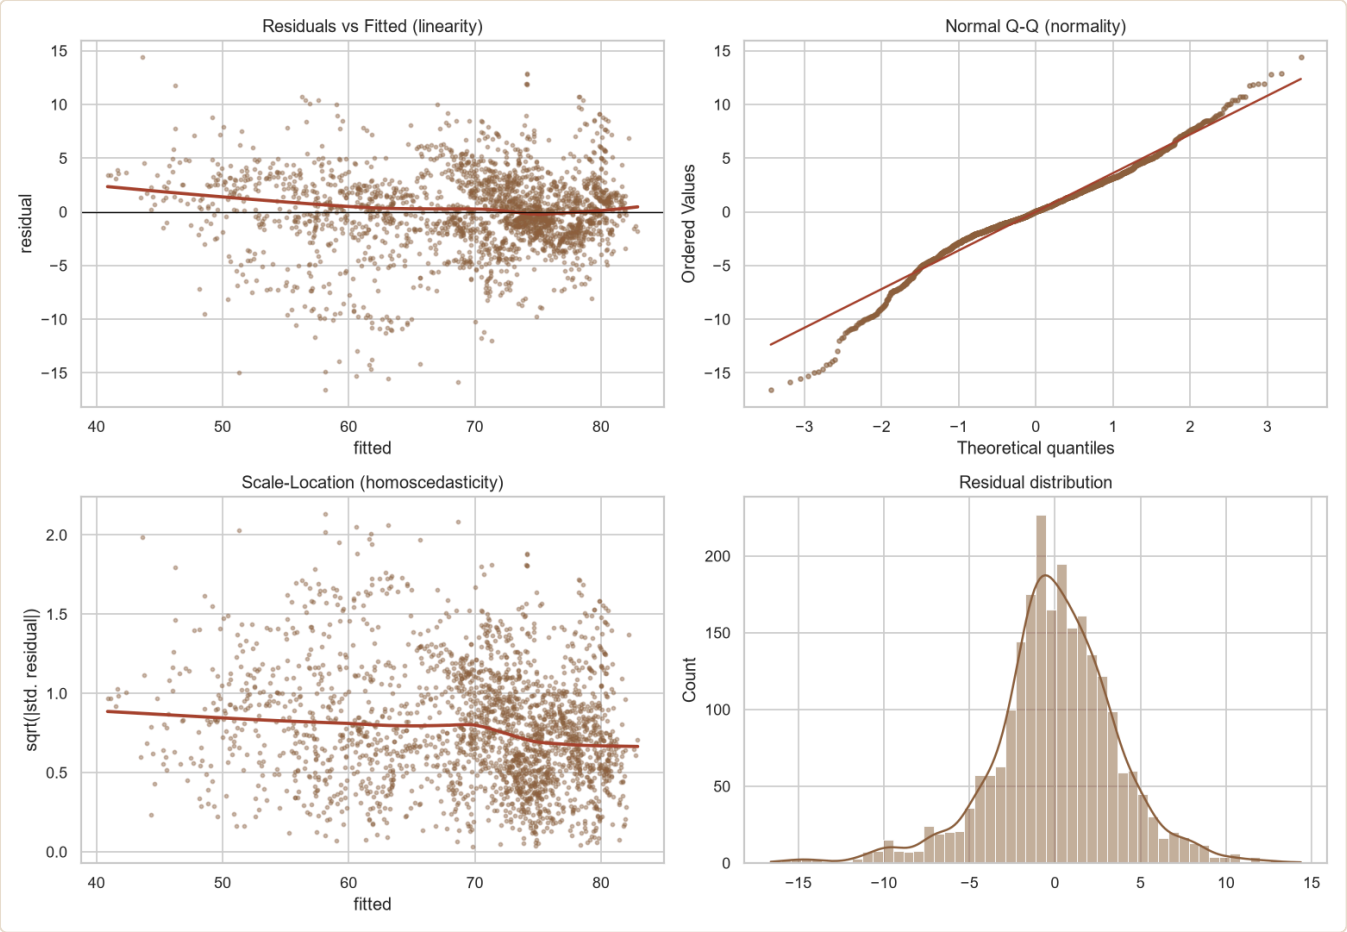
## 5.1 預測圖與 95% 信賴區間 / 預測區間




- 平均 CI 寬度 0.84 歲；平均 PI 寬度 14.4 歲（約 ±7.2 歲）
- **測試集 95% PI 實際覆蓋率 91.2%**，略低於 95%。原因是測試國家完全沒出現在訓練集，國家層級的差異無法完全由特徵解釋（分布偏移）。

## 5.2 五大回歸假設

| 假設 | 檢定 | 結果 | 說明 |
|---|---|---|---|
| 線性 | Rainbow F = 1.16, p = 0.006 | ✗ | 輕微非線性（高壽命區間預測偏低） |
| 獨立性 | Durbin-Watson = 0.64 | ✗ | panel data：同國家逐年誤差高度相關 |
| 同質變異 | Breusch-Pagan p < 0.001 | ✗ | 低壽命國家的殘差變異較大 |
| 常態性 | Jarque-Bera p < 0.001 | ✗ | 大樣本下輕微重尾，影響有限 |
| 無多重共線性 | max VIF = 2.33 | ✓ | 特徵選擇後已剔除 VIF > 10 的特徵 |




**因應方式**：違反獨立性與同質變異時，OLS 係數仍然不偏，但標準誤會被低估，因此改用**以國家為群集的穩健標準誤**（cluster-robust SE）判斷顯著性。7 個特徵在穩健 SE 下仍然全部顯著（$p < 0.01$）。未來可改用固定效果或混合效果模型。

### 5.3 Problem 2：成人死亡率

| 模型 | k | $R^2$ | RMSE |
|---|---|---|---|
| Baseline（HIV/AIDS） | 1 | 0.370 | 101.8 |
| OLS – 全部特徵 | 19 | 0.426 | 97.3 |
| **OLS – 特徵選擇後（HIV/AIDS、收入組成）** | **2** | **0.419** | **97.8** |
| LassoCV | 19 | 0.430 | 96.9 |

只用 2 個特徵，$R^2$ 就和 19 個特徵相當，但整體解釋力只有約 0.42。PI 覆蓋率為 94.4%，可是平均寬度達 357‰，實用性低。原因是這個欄位本身雜訊很大，例如有國家某些年份的成人死亡率僅 1–10，明顯是登錄錯誤。這個對照凸顯了**資料品質對線性回歸的影響**。

## 6. Deployment

1. 以全部資料（2,928 筆）重新估計 7 特徵 OLS（$R^2 = 0.848$）
2. 匯出係數、共變異矩陣 $\sigma^2(X^TX)^{-1}$、補值中位數、log 設定 → `model/problem1.json`
3. 網站（Vercel 靜態部署）讀取 JSON，在瀏覽器即時計算： - 預測值 $\hat{y} = x^T\beta$ - CI = $\hat{y} \pm t \cdot \sqrt{(x^T\Sigma x)}$，PI = $\hat{y} \pm t \cdot \sqrt{(\sigma^2 + x^T\Sigma x)}$

4. 互動功能：選國家帶入最新年度數值（例：Japan 2015 實際 83.7 歲、預測 79.8 歲，PI [72.5, 87.1]），或拖曳滑桿做 what-if 模擬

### 本機執行

```
# 網站（需透過 HTTP 伺服器，直接雙擊 index.html 會無法讀取 JSON）
python -m http.server 8000      # 開啟 http://localhost:8000

# 重新產生分析與 model/*.json
pip install -r requirements.txt
jupyter lab notebooks/HW2_Life_Expectancy_Regression.ipynb
```

### 部署到 Vercel

把 repo 推上 GitHub → Vercel「Add New Project」→ 匯入此 repo → Framework Preset 選 **Other**，Build Command 與 Output Directory 留空 → Deploy。

---

## 結論

1. 在**沒看過的國家**上，7 個特徵的 OLS 可解釋 81% 的平均壽命變異（RMSE 4.2 歲），遠優於單一特徵 baseline（53%）。
2. 收入組成（HDI）、HIV/AIDS、成人死亡率是最主要的三個因子；疫苗覆蓋率有額外但較小的貢獻。
3. 特徵選擇的真正價值不在提升 $R^2$，而在**去除共線性、讓係數可解釋**。全特徵模型多 0.03 $R^2$，但係數互相抵消。
4. Panel data 違反誤差獨立，需要以分組切分評估、以 cluster-robust SE 推論，否則會高估模型表現與顯著性。

---

## 【GPT 輔助內容】（本作業使用 Claude）

> 本作業的 AI 輔助工具為 **Claude（Anthropic），透過 VS Code 的 Claude Code 擴充功能使用**，未使用 ChatGPT。
>
> 對話紀錄 PDF（節錄與分析、建模、部署相關的專業討論）：notebooks/Claude_conversation.pdf

| 項目 | Claude 協助內容 | 本人確認 / 決定 |
|---|---|---|
| 資料集選擇 | 確認 WHO Life Expectancy 共 20 個特徵，符合 >13 的要求；從 GitHub 鏡像下載 Kaggle 原始檔 | 本人選定「各國平均壽命（WHO）」主題 |
| 資料前處理 | 指出 0 值缺值代碼、右偏欄位 log 轉換、panel data 需依國家分組切分 | 確認處理方式 |
| 特徵選擇 | 實作 5 種方法比較；1-SE rule 只留 3 個特徵、測試 $R^2$ 下降，改為 1% 容忍度 + VIF 剔除 | 詢問並確認最終特徵為 7 個的原因 |
| 評估 | CI / PI、五大假設檢驗、cluster-robust SE | 逐項對照作業「分析任務」要求，確認皆已完成 |
| 網站與部署 | HTML/JS 靜態網站、瀏覽器端 OLS 與 t 分配，並用 Python statsmodels 驗證 JS 計算結果一致；修正 Vercel 誤判為 Python 專案的部署錯誤 | 指定以 Vercel 部署；自行上傳 GitHub、部署 Vercel |
| 網頁風格 | 將網頁與圖表改為奶茶 / 大地色系 | 本人提出風格需求 |
| 對照範本補強 | 比對老師推薦的範本 repo，補上資訊圖表、網頁截圖、報告書 PDF、預測樣本表 | 決定「兩種 problem」維持兩個預測任務的解讀 |
| NotebookLM | 提供研究來源建議與提問內容；撰寫「與本作業的比較」表 | 本人操作 NotebookLM 產生摘要 |

## 【NotebookLM 摘要】

> 以 NotebookLM 研究網路上使用同一份 WHO Life Expectancy 資料集的解法，以下為 NotebookLM 產生的摘要。

**WHO Life Expectancy 資料集預測平均壽命方法摘要：**

1. **資料前處理**：常以國家中位數或全域中位數填補缺失值，或直接剔除缺值過多之欄位；異常值主要採用 **1.5×IQR 規則**或**極限截斷（Capping）**處理；對偏態嚴重之特徵（如 GDP、HIV/AIDS 及人口數）則進行 **Log 轉換**。
2. **模型與特徵選擇**：主要採用**線性回歸（Linear Regression）**與**隨機森林（Random Forest）**。特徵選擇則結合相關性矩陣（排除高度相關特徵 $|r| > 0.75$）、逐步前向選擇法（Forward Selection）及 P 值顯著性檢定（$p \leq 0.05$）。
3. **重要特徵**：**受教育年限（Schooling）**與**收入資源組成（Income Composition / HDI）**是最關鍵的正向預測特徵，而**成人死亡率**與 **HIV/AIDS** 則是主要的負向特徵。
4. **模型表現**：線性回歸模型在測試集上的 $R^2$ 大約落在 **0.85** 左右，RMSE 大約為 **3.57–3.63 年**。
5. **模型優缺點對比**：線性回歸**可解釋性高、結構簡單**，但較難自動捕捉非線性關係與複合特徵互動；隨機森林等非線性模型能有效處理複雜互動與異常值，**預測準確度與 $R^2$ 通常更高**，但模型屬於灰黑盒，**可解釋性較低**。

**參考來源（NotebookLM 加入的資料）：**

- Kaggle 資料集頁面：https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who
- https://github.com/Akshu577/life-expectancy-analysis（回歸與特徵選擇）
- https://github.com/SamruddhiGoswami/LifeExpectancyAnalysis（線性回歸與殘差診斷）

- https://github.com/ranjeetmaurya-git/Life-Expectancy-Analysis-Project（多種回歸模型與 Streamlit）
- https://github.com/NysaSetiawan/LifeExpectancyAnalysis（R Shiny 互動儀表板）

### 與本作業的比較（本人分析，非 NotebookLM 產生）

| 面向 | 網路上常見做法 | 本作業 |
|---|---|---|
| 缺值、偏態 | 中位數補值、log 轉換 | 相同；另外把 `income_composition`、`schooling` 的 0 值視為缺值代碼 |
| 特徵選擇 | 相關矩陣、前向選擇、p 值 | 比較 5 種方法（含前向選擇 SFS），再以 VIF > 10 剔除共線特徵 |
| 重要特徵 | 教育、收入組成（正向）；成人死亡率、HIV（負向） | 結論一致；本作業選出的 7 個特徵中，收入組成、HIV/AIDS、成人死亡率影響最大（教育年數與收入組成高度相關 r = 0.92，資訊重疊，因此未入選） |
| 線性回歸表現 | $R^2 \approx 0.85$、RMSE ≈ 3.6 年 | 全特徵 $R^2$ 0.845、RMSE 3.80；7 特徵 $R^2$ 0.811、RMSE 4.21 |
| 資料切分 | 多為隨機切分 | **依國家分組切分**，測試集是 37 個完全沒看過的國家 |

本作業的 $R^2$ 略低於網路上常見的結果，主要原因是切分方式不同。隨機切分時，同一國家其他年份的資料已經出現在訓練集，模型等於「看過答案」，分數會偏高。本作業以國家分組切分，評估的是模型對**新國家**的預測能力，結果較保守，但更接近真實應用情境。