AIoT HW2：WHO 各國平均壽命預測 — 多元線性回歸（CRISP-DM）

報告日期：2026-10-27

目錄

- 【資訊圖表】CRISP-DM Infographic
- 📦 繳交成果檔案清單（Deliverables）
- 加分項目對照
- 網頁截圖
- 專案結構
- 1. Business Understanding
- 2. Data Understanding
- 3. Data Preparation
- 4. Modeling
- 5. Evaluation
- 6. Deployment
- 結論
- 【GPT 輔助內容】（本作業使用 Claude）
- 【NotebookLM 摘要】

- 🌐 **線上網站（Vercel）**：https://1028hw2-pearl.vercel.app/
- 💻 **GitHub**：https://github.com/susuannie/1028HW2
- 📓 **Notebook**：notebooks/HW2_Life_Expectancy_Regression.ipynb
- 📊 **資料集**：Life Expectancy (WHO) — Kaggle, KumarRajarshi
- 📄 **報告書 PDF**：notebooks/HW2_report.pdf

以 WHO 公開的各國健康與社經指標（193 國、2000–2015、2,938 筆、**20 個特徵**）進行多元線性回歸，依 CRISP-DM 完成資料理解、前處理、特徵選擇、建模、評估（含 95% 信賴 / 預測區間與五大回歸假設檢驗）到網頁部署。

【資訊圖表】CRISP-DM Infographic

> 作業 optional 項目「資訊圖表」：以一張圖呈現 CRISP-DM 六階段流程、Problem 1 成果指標、模型比較與主要影響因子。原始檔：assets/crisp_dm_infographic.png



繳交成果檔案清單（Deliverables）

類別	檔案 / 連結	說明
主要繳交	GitHub Repo	完整專案原始碼、分析與報告
主要繳交	線上網站（`index.html`）	互動式分析平台：Problem 1、Problem 2 與自訂資料集
主程式	notebooks/HW2_Life_Expectancy_Regression.ipynb	CRISP-DM 六階段完整程式碼與統計推論
Optional 1	notebooks/HW2_report.pdf	書面報告書
Optional 2	notebooks/Claude_conversation.pdf	Claude 對話紀錄（節錄）
Optional 3	assets/crisp_dm_infographic.png	CRISP-DM 資訊圖表
完整封裝	notebooks/HW2_package.zip	Notebook、報告書、對話紀錄與資訊圖表的壓縮檔

加分項目對照

加分要求	實作
✅ 下拉選單呈現兩種 problem（+1）	網頁頂端下拉選單：**Problem 1 預測平均壽命**、**Problem 2 預測成人死亡率**，兩者都有完整的特徵選擇、模型比較、區間圖、假設檢驗與互動預測
✅ 可任意輸入 Dataset（+2）	下拉選單第 3 項「自訂資料集」：輸入 CSV 網址（預設 `50_Startups.csv`）或上傳檔案 → 自動判斷數值 / 類別欄位、one-hot、選目標與特徵、OLS、係數 t 檢定、95% CI / PI 預測圖、**後向消去法**、新樣本預測，全部在瀏覽器計算

網頁截圖

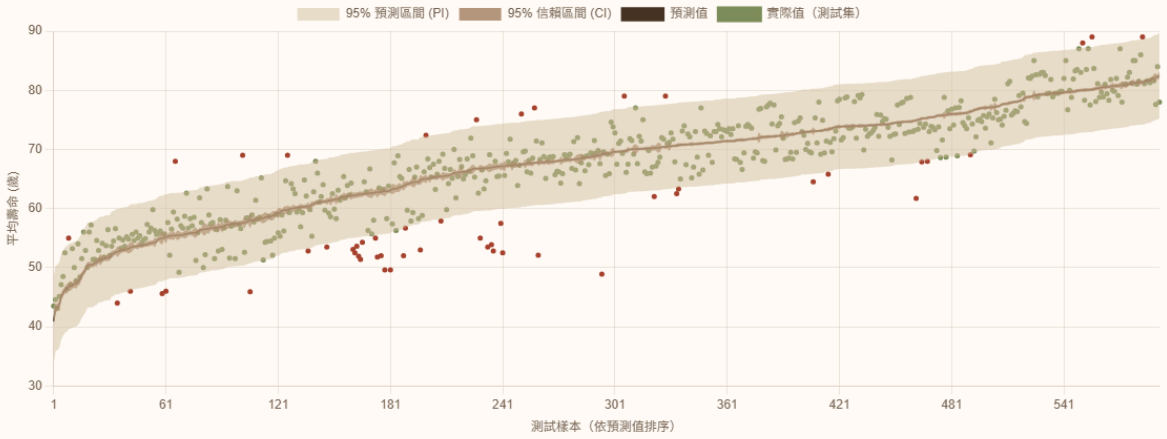
Problem 1：KPI 與互動預測（選國家帶入數值、拖曳滑桿，即時計算預測值與 95% CI / PI）



預測圖與 95% 信賴 / 預測區間，以及測試集預測樣本表

預測圖：95% 信賴區間與預測區間（測試集）

測試集為 37 個完全沒出現在訓練集的國家（592 筆）。焦糖色帶 = 平均值的信賴區間，奶茶色帶 = 單一觀測的預測區間；綠點 = 實際值，赤陶色點 = 落在 PI 外。平均 CI 寬度 0.84、PI 寬度 14.36 歲。



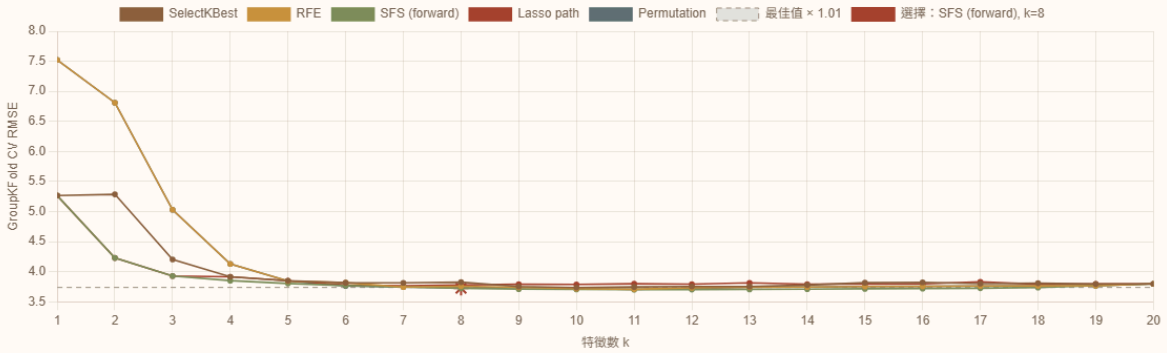
測試集預測樣本（2015 年，依預測值平均抽取 10 國）

國家	實際	預測	誤差	95% CI	95% PI	落在 PI 內
South Sudan	57.3	54.0	+3.3	[53.5, 54.4]	[46.8, 61.2]	✓
Guinea-Bissau	58.9	58.0	+0.9	[57.7, 58.4]	[50.9, 65.2]	✓
Niger	61.8	62.0	-0.2	[61.5, 62.5]	[54.8, 69.2]	✓
United Republic of Tanzania	61.8	66.0	-4.2	[65.6, 66.5]	[58.8, 73.2]	✓
Solomon Islands	69.2	68.2	+1.0	[67.8, 68.7]	[61.1, 75.4]	✓
El Salvador	73.5	71.4	+2.1	[71.2, 71.6]	[64.2, 78.6]	✓
Belize	71.0	73.0	-2.0	[72.7, 73.2]	[65.8, 80.1]	✓
Czechia	78.8	74.7	+4.1	[74.4, 75.0]	[67.5, 81.9]	✓
Slovenia	88.0	80.0	+8.0	[79.7, 80.3]	[72.8, 87.2]	✗
Norway	81.8	81.9	-0.1	[81.5, 82.2]	[74.7, 89.0]	✓

特徵選擇：5 種方法的 CV RMSE 曲線

特徵選擇（Feature Selection）

5 種方法各自產生特徵排序，以**訓練集** GroupKFold(5) 交叉驗證 RMSE 評估前 k 個特徵。最佳為 SFS (forward) k=11（RMSE 3.700）；在「最佳值 × 1.01」內選最小 k → **SFS (forward)，k = 8**，再以 VIF > 10 剔除共線特徵。



最終特徵

人類發展指數-收入組成 (0–1) · HIV/AIDS 死亡 (每千活產, 0–4歲) · 成人死亡率 (每千人, 15–60歲) · 小兒麻痺疫苗覆蓋率 (%) · 嬰兒死亡數 (每千人口) · 白喉疫苗覆蓋率 (%) · B肝疫苗覆蓋率 (%) · ~~五歲以下死亡數 (每千人口)（VIF 198）~~

Problem 2：成人死亡率（下拉選單切換）



加分：自訂資料集（預設載入 50_Startups.csv，自動 one-hot，提供後向消去法）

AIoT 物聯網數據分析與應用 • HW2 Multiple Linear Regression

WHO 各國平均壽命 — 多元線性回歸

資料集：Life Expectancy (WHO) • Kaggle • 193 國 × 2000–2015 • 2,938 筆 • 20 個特徵 • 依 CRISP-DM 流程

選擇問題 ★ 自訂資料集：輸入任意 CSV（URL／上傳）

自訂資料集回歸

輸入 CSV 網址或上傳檔案，系統自動判斷數值／類別欄位（類別欄位做 one-hot，去掉第一個水準避免虛擬變數陷阱），在瀏覽器以 $\beta = (X^TX)^{-1}X^Ty$ 計算 OLS，並給出 95% 信賴區間與預測區間。網址需允許跨網域讀取（例如 raw.githubusercontent.com）。

https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv

載入網址

上傳 CSV | 範例：50_Startups | 範例：WHO Life Expectancy

已載入：50_Startups.csv（範例） — 50 筆 × 5 欄

R&D Spend 數值	Administration 數值	Marketing Spend 數值	State 類別 (one-hot)	Profit 數值
165349.2	136897.8	471784.1	New York	192261.83
162597.7	151377.59	443898.53	California	191792.06
153441.51	101145.55	407934.54	Florida	191050.39
144372.41	118671.85	383199.62	New York	182901.99
142107.34	91391.77	366168.42	Florida	166187.94

設定模型

目標變數 (y)

Profit

特徵 (X)

全選 | 全不選

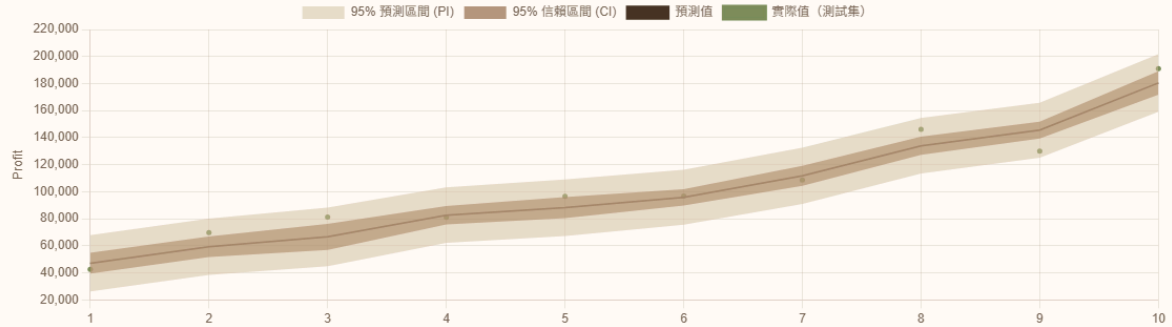
- ☑ R&D Spend 數值
- ☑ Administration 數值
- ☑ Marketing Spend 數值
- ☑ State 類別・3

測試集比例 0.2 隨機種子 42

執行回歸 | 後向消去法（p > 0.05）

訓練集 R^2	測試集 R^2	測試集 RMSE	測試集 MSE	95% PI 覆蓋率
0.951	0.942	9,668	93,470,948	100.0%
Adj R^2 0.944	Adj R^2 0.870	MAE 8,223	n_train 40 / n_test 10	σ̂ = 9,530

預測圖（測試集）：95% 信賴區間與預測區間



專案結構

```
├── index.html / style.css / app.js   # Vercel 靜態網站（Chart.js；OLS 與 t 分配在瀏覽器計算）
├── vercel.json
├── model/problem1.json, problem2.json # Notebook 匯出的最終模型、評估結果、圖表資料
├── notebooks/HW2_Life_Expectancy_Regression.ipynb
├── notebooks/HW2_report.pdf           # 報告書（由本 README 產生）
├── notebooks/Claude_conversation.pdf  # AI（Claude）對話紀錄
├── notebooks/HW2_package.zip          # 完整封裝（ipynb + 報告書 + 對話紀錄 + 資訊圖表）
├── data/Life Expectancy Data.csv      # Kaggle 原始資料
├── data/50_Startups.csv               # 自訂資料集範例
├── assets/crisp_dm_infographic.png    # CRISP-DM 資訊圖表
├── assets/web_*.png                   # 網頁截圖
├── assets/*.png                       # Notebook 輸出圖表
├── tools/build_report.py              # README → 報告書 PDF
├── tools/export_conversation.py       # Claude Code 對話紀錄 → 對話 PDF
└── requirements.txt                   # Notebook 所需套件
```

---

1. Business Understanding

平均壽命是衡量國家健康與發展最常用的指標。本作業想回答：

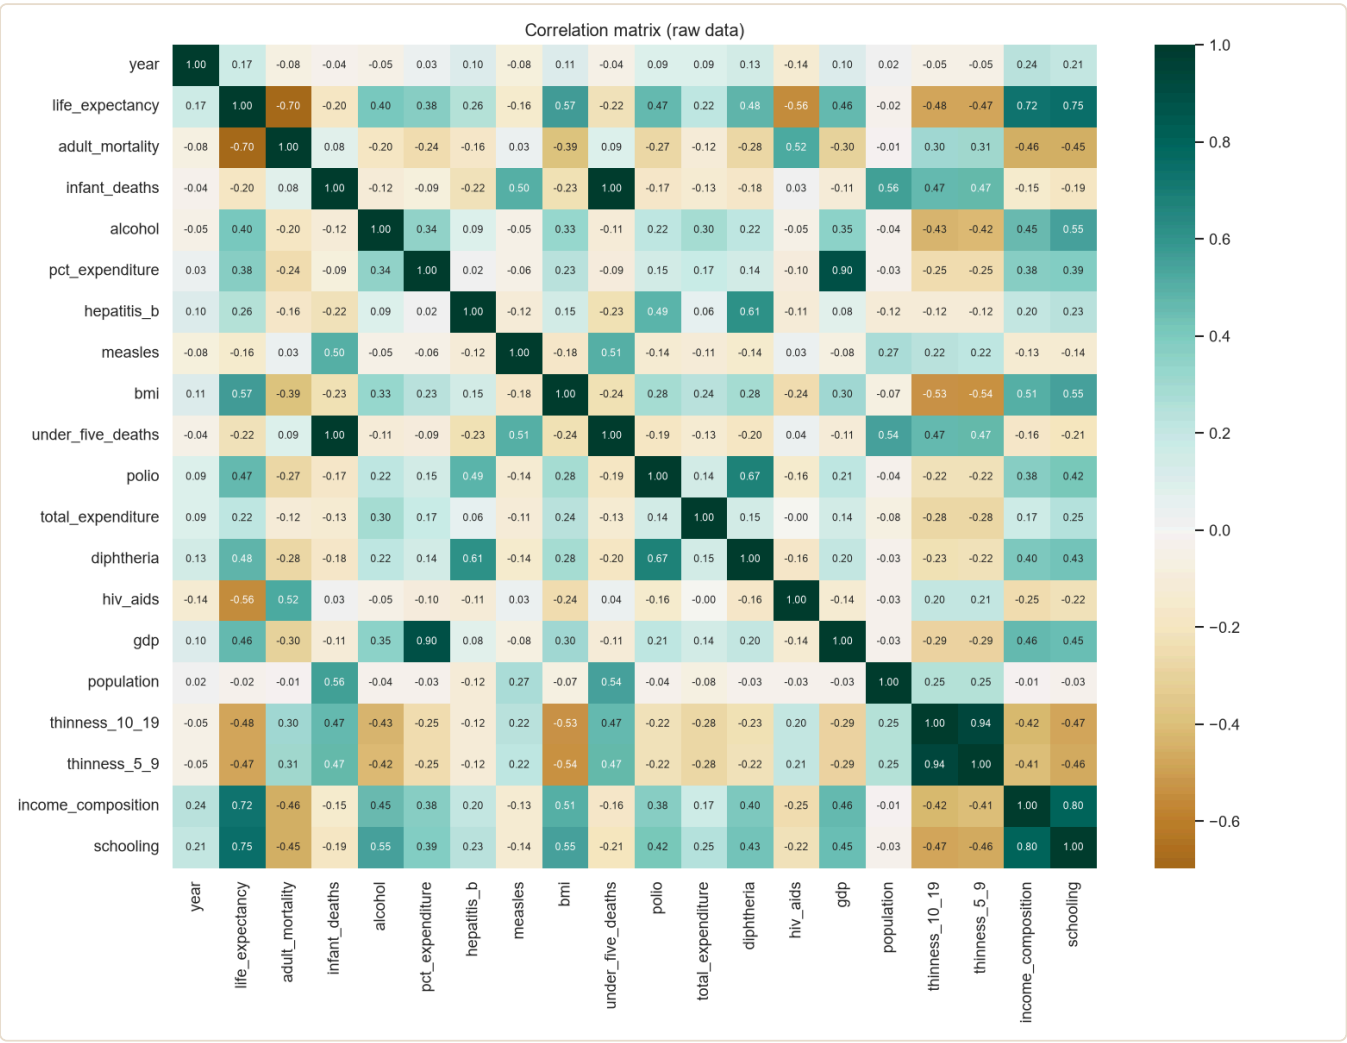
1. 哪些健康與社經因子與平均壽命關係最強？
2. 給定一國的指標，能否預測其平均壽命，並給出**不確定性範圍**？

	Problem 1	Problem 2
目標 y	平均壽命（歲）	成人死亡率（15–60 歲每千人死亡數）
候選特徵	20	19（排除平均壽命，避免目標洩漏）
成功標準	在「沒看過的國家」上 $R^2 \geq 0.80$	對照問題：觀察雜訊較大的目標

2. Data Understanding

- 2,938 筆 × 22 欄；扣除目標與 `Country`（識別碼）後 20 個特徵。
- 缺值最多：Population 22%、Hepatitis B 19%、GDP 15%。
- 與平均壽命相關最強：受教育年數 **+0.75**、收入組成（HDI）**+0.72**、成人死亡率 **−0.70**、HIV/AIDS **−0.56**。
- 高度共線的特徵：`infant_deaths` ↔ `under_five_deaths`（r ≈ 0.997）、兩個消瘦率（0.94）、`pct_expenditure` ↔ `gdp`（0.90）。
- 資料品質問題：`income_composition`、`schooling` 有不合理的 0；`bmi` 有大量不合理值；多個欄位嚴重右偏（偏態 3 ~ 16）。





3. Data Preparation

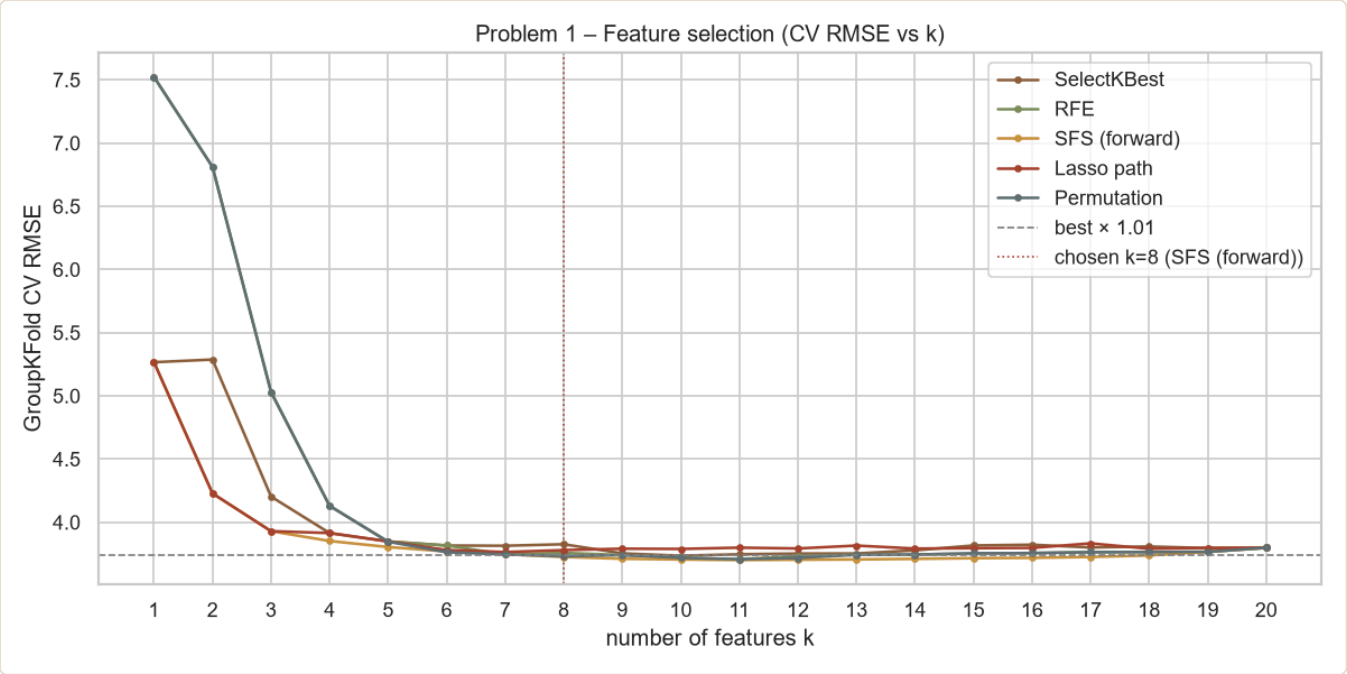
1. `Status` → `developed`（0/1）
2. `income_composition == 0`、`schooling == 0` → 缺值
3. 7 個右偏欄位（infant_deaths、pct_expenditure、measles、under_five_deaths、hiv_aids、gdp、population）做 `log1p`，例如 population 的偏態從 15.9 降到 −0.6
4. **以國家分組切分**（`GroupShuffleSplit`，80/20）：train 2,336 筆 / 146 國，test 592 筆 / 37 國，兩邊國家**零重疊**。這是 panel data，隨機切分會讓同一國家的其他年份洩漏到訓練集。
5. 缺值補訓練集中位數、標準化只在訓練集 fit（包在 Pipeline 中，CV 每一折各自 fit）

4. Modeling

4.1 特徵選擇（只用訓練資料）

5 種方法各產生一個特徵排序，再以 **GroupKFold(5) CV RMSE** 評估前 k 個特徵（k = 1…20）：

方法	類型
SelectKBest (f_regression)	Filter
RFE (LinearRegression)	Wrapper
Sequential Feature Selection (forward)	Wrapper
Lasso path（進入順序）	Embedded
Permutation importance	Model-agnostic



- 全域最佳：SFS k = 11，CV RMSE 3.700
- 規則：在「最佳值 × 1.01」內選最小 k → **SFS，k = 8**（也試過 1-SE rule，但分組 CV 標準誤大，只會留下 3 個特徵，測試集 R^2 掉到 0.79）
- VIF 檢查：`under_five_deaths` VIF = **197.6**（與 infant_deaths 幾乎相同），剔除
- **最終 7 個特徵**：收入組成、HIV/AIDS、成人死亡率、小兒麻痺疫苗、嬰兒死亡數、白喉疫苗、B 肝疫苗

4.2 模型比較（Problem 1，測試集 = 37 個沒看過的國家）

模型	k	Train R^2	MAE	MSE	RMSE	R^2	Adj R^2
Baseline 簡單線性回歸（收入組成）	1	0.693	4.68	43.53	6.60	0.534	0.533
OLS – 全部特徵	20	0.862	2.88	14.47	3.80	0.845	0.840
OLS – 特徵選擇後	**7**	**0.850**	**3.09**	**17.71**	**4.21**	**0.811**	**0.808**
RidgeCV – 全部特徵	20	0.862	2.88	14.46	3.80	0.845	0.840
LassoCV – 全部特徵	20	0.862	2.85	14.31	3.78	0.847	0.841

解讀

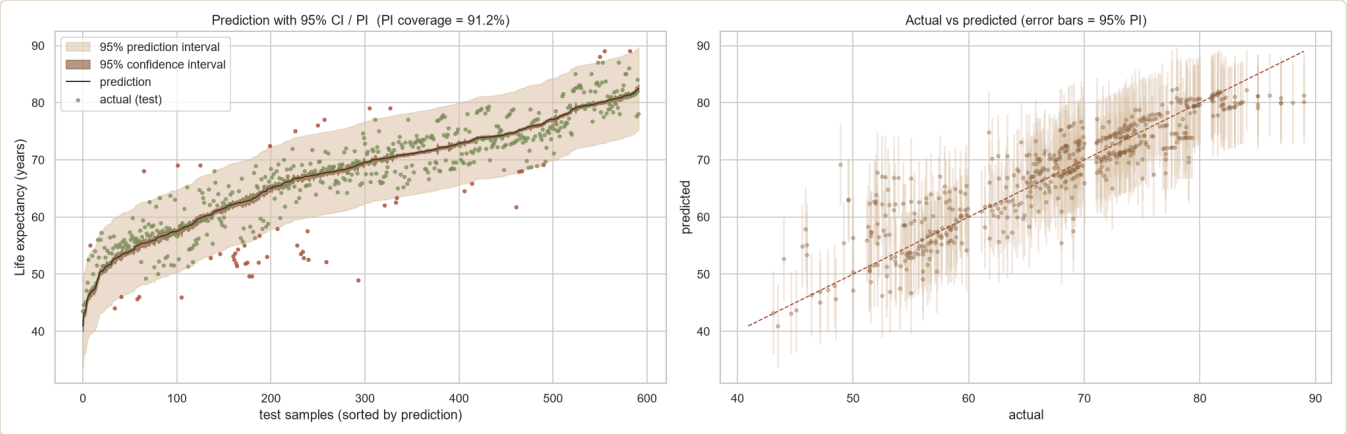
- 多元回歸比單一特徵 baseline 的 R^2 高出約 0.28。
- 全特徵模型的 R^2 多 0.03，但 `infant_deaths` 與 `under_five_deaths` 的標準化係數分別約 +7.2 和 −8.4，互相抵消（VIF 近 200），沒有解釋意義。
- 7 特徵模型的 VIF 全都 < 2.4，係數穩定、可以解釋，最後選它部署。
- Ridge / Lasso 與 OLS 幾乎相同，表示在此樣本量下過擬合不是主要問題。

4.3 最終係數（訓練集 OLS，cluster-robust p 值）

特徵	係數	p_cluster	解讀
收入組成 (0–1)	+26.93	<0.001	HDI 收入組成每 +0.1 → 壽命 +2.7 歲
HIV/AIDS（log1p）	−3.41	<0.001	HIV 死亡率越高壽命越低
成人死亡率	−0.0171	<0.001	每千人多 100 人死亡 → −1.7 歲
小兒麻痺疫苗 (%)	+0.025	0.003	
嬰兒死亡數（log1p）	−0.61	0.005	
白喉疫苗 (%)	+0.037	<0.001	
B 肝疫苗 (%)	−0.024	<0.001	符號為負：與另兩種疫苗高度相關，是控制其他疫苗後的「抑制效果」，不宜做因果解讀

5. Evaluation

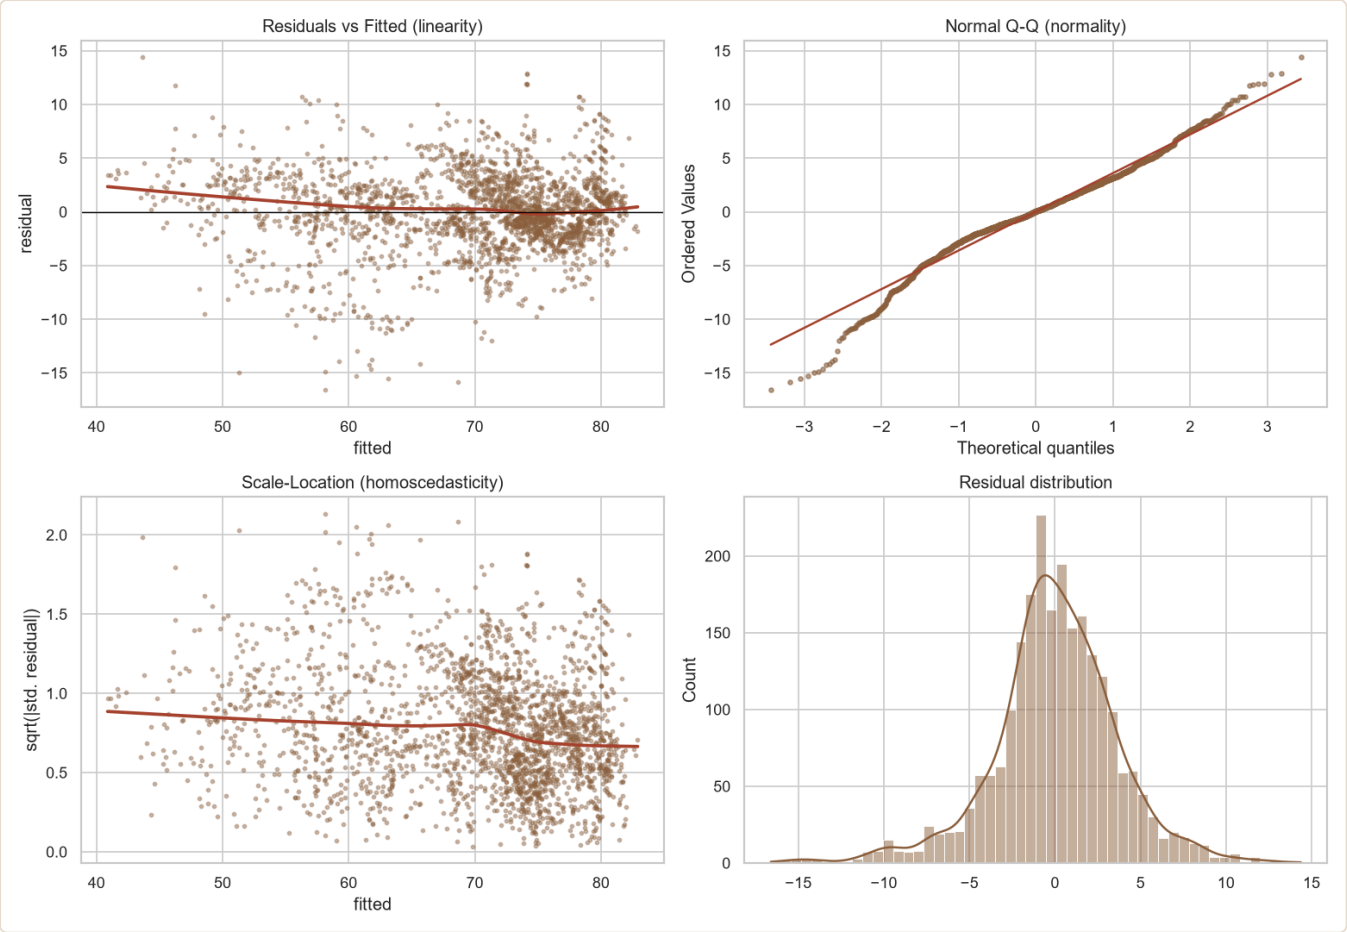
5.1 預測圖與 95% 信賴區間 / 預測區間



- 平均 CI 寬度 0.84 歲；平均 PI 寬度 14.4 歲（約 ±7.2 歲）
- **測試集 95% PI 實際覆蓋率 91.2%**，略低於 95%。原因是測試國家完全沒出現在訓練集，國家層級的差異無法完全由特徵解釋（分布偏移）。

5.2 五大回歸假設

假設	檢定	結果	說明
線性	Rainbow F = 1.16, p = 0.006	✗	輕微非線性（高壽命區間預測偏低）
獨立性	Durbin-Watson = 0.64	✗	panel data：同國家逐年誤差高度相關
同質變異	Breusch-Pagan p < 0.001	✗	低壽命國家的殘差變異較大
常態性	Jarque-Bera p < 0.001	✗	大樣本下輕微重尾，影響有限
無多重共線性	max VIF = 2.33	✓	特徵選擇後已剔除 VIF > 10 的特徵



因應方式：違反獨立性與同質變異時，OLS 係數仍然不偏，但標準誤會被低估，因此改用**以國家為群集的穩健標準誤**（cluster-robust SE）判斷顯著性。7 個特徵在穩健 SE 下仍然全部顯著（$p < 0.01$）。未來可改用固定效果或混合效果模型。

5.3 Problem 2：成人死亡率

模型	k	R^2	RMSE
Baseline（HIV/AIDS）	1	0.370	101.8
OLS – 全部特徵	19	0.426	97.3
OLS – 特徵選擇後（HIV/AIDS、收入組成）	**2**	**0.419**	**97.8**
LassoCV	19	0.430	96.9

只用 2 個特徵，R^2 就和 19 個特徵相當，但整體解釋力只有約 0.42。PI 覆蓋率為 94.4%，可是平均寬度達 357‰，實用性低。原因是這個欄位本身雜訊很大，例如有國家某些年份的成人死亡率僅 1–10，明顯是登錄錯誤。這個對照凸顯了**資料品質對線性回歸的影響**。

6. Deployment

1. 以全部資料（2,928 筆）重新估計 7 特徵 OLS（$R^2 = 0.848$）
2. 匯出係數、共變異矩陣 $\sigma^2(X^TX)^{-1}$、補值中位數、log 設定 → `model/problem1.json`
3. 網站（Vercel 靜態部署）讀取 JSON，在瀏覽器即時計算： - 預測值 $\hat{y} = x^T\beta$ - CI = $\hat{y} \pm t \cdot \sqrt{(x^T\Sigma x)}$，PI = $\hat{y} \pm t \cdot \sqrt{(\sigma^2 + x^T\Sigma x)}$

4. 互動功能：選國家帶入最新年度數值（例：Japan 2015 實際 83.7 歲、預測 79.8 歲，PI [72.5, 87.1]），或拖曳滑桿做 what-if 模擬

本機執行

```
# 網站（需透過 HTTP 伺服器，直接雙擊 index.html 會無法讀取 JSON）
python -m http.server 8000      # 開啟 http://localhost:8000

# 重新產生分析與 model/*.json
pip install -r requirements.txt
jupyter lab notebooks/HW2_Life_Expectancy_Regression.ipynb
```

部署到 Vercel

把 repo 推上 GitHub → Vercel「Add New Project」→ 匯入此 repo → Framework Preset 選 **Other**，Build Command 與 Output Directory 留空 → Deploy。

結論

1. 在**沒看過的國家**上，7 個特徵的 OLS 可解釋 81% 的平均壽命變異（RMSE 4.2 歲），遠優於單一特徵 baseline（53%）。
2. 收入組成（HDI）、HIV/AIDS、成人死亡率是最主要的三個因子；疫苗覆蓋率有額外但較小的貢獻。
3. 特徵選擇的真正價值不在提升 R^2，而在**去除共線性、讓係數可解釋**。全特徵模型多 0.03 R^2，但係數互相抵消。
4. Panel data 違反誤差獨立，需要以分組切分評估、以 cluster-robust SE 推論，否則會高估模型表現與顯著性。

【GPT 輔助內容】（本作業使用 Claude）

> 本作業的 AI 輔助工具為 **Claude（Anthropic），透過 VS Code 的 Claude Code 擴充功能使用**，未使用 ChatGPT。
>
> 對話紀錄 PDF（節錄與分析、建模、部署相關的專業討論）：notebooks/Claude_conversation.pdf

項目	Claude 協助內容	本人確認 / 決定
資料集選擇	確認 WHO Life Expectancy 共 20 個特徵，符合 >13 的要求；從 GitHub 鏡像下載 Kaggle 原始檔	本人選定「各國平均壽命（WHO）」主題
資料前處理	指出 0 值缺值代碼、右偏欄位 log 轉換、panel data 需依國家分組切分	確認處理方式
特徵選擇	實作 5 種方法比較；1-SE rule 只留 3 個特徵、測試 R^2 下降，改為 1% 容忍度 + VIF 剔除	詢問並確認最終特徵為 7 個的原因
評估	CI / PI、五大假設檢驗、cluster-robust SE	逐項對照作業「分析任務」要求，確認皆已完成
網站與部署	HTML/JS 靜態網站、瀏覽器端 OLS 與 t 分配，並用 Python statsmodels 驗證 JS 計算結果一致；修正 Vercel 誤判為 Python 專案的部署錯誤	指定以 Vercel 部署；自行上傳 GitHub、部署 Vercel
網頁風格	將網頁與圖表改為奶茶 / 大地色系	本人提出風格需求
對照範本補強	比對老師推薦的範本 repo，補上資訊圖表、網頁截圖、報告書 PDF、預測樣本表	決定「兩種 problem」維持兩個預測任務的解讀
NotebookLM	提供研究來源建議與提問內容；撰寫「與本作業的比較」表	本人操作 NotebookLM 產生摘要

嚴謹校驗紀錄（實際驗證與修正）

1. **特徵選擇規則修正**：原先採 1-SE rule，只留下 3 個特徵、測試 R^2 降至 0.789；改為「CV RMSE 不超過最佳值 1%」後選出 8 個特徵，再以 VIF 剔除五歲以下死亡數（VIF 198），最終 7 個特徵、R^2 0.811。
2. **網頁計算交叉驗證**：瀏覽器端 JavaScript 的 OLS 與 t 分配，以 Python statsmodels 對 50_Startups 逐項比對，係數、標準誤、p 值、95% CI / PI 皆一致。
3. **文字敘述先驗證再寫入**：「教育年數與收入組成高度相關」經實際計算 r = 0.92 後才寫入報告。
4. **如實報告區間覆蓋率**：95% 預測區間在測試集的實測覆蓋率為 91.2%（非理論值 95%），並說明是未見過國家的分布偏移所致。
5. **部署錯誤修正**：Vercel 因 requirements.txt 誤判為 Python 專案而建置失敗，以 vercel.json 指定靜態網站並加入 .vercelignore 修正。

【NotebookLM 摘要】

> 以 NotebookLM 研究網路上使用同一份 WHO Life Expectancy 資料集的解法，以下為 NotebookLM 產生的摘要。

WHO Life Expectancy 資料集預測平均壽命方法摘要：

1. **資料前處理**：常以國家中位數或全域中位數填補缺失值，或直接剔除缺值過多之欄位；異常值主要採用 **1.5×IQR 規則**或**極限截斷（Capping）**處理；對偏態嚴重之特徵（如 GDP、HIV/AIDS 及人口數）則進行 **Log 轉換**。

2. **模型與特徵選擇**：主要採用**線性回歸（Linear Regression）**與**隨機森林（Random Forest）**。特徵選擇則結合相關性矩陣（排除高度相關特徵 $|r| > 0.75$）、逐步前向選擇法（Forward Selection）及 P 值顯著性檢定（$p \leq 0.05$）。
3. **重要特徵**：**受教育年限（Schooling）**與**收入資源組成（Income Composition / HDI）**是最關鍵的正向預測特徵，而**成人死亡率**與 **HIV/AIDS** 則是主要的負向特徵。
4. **模型表現**：線性回歸模型在測試集上的 R^2 大約落在 **0.85** 左右，RMSE 大約為 **3.57–3.63 年**。
5. **模型優缺點對比**：線性回歸**可解釋性高、結構簡單**，但較難自動捕捉非線性關係與複合特徵互動；隨機森林等非線性模型能有效處理複雜互動與異常值，**預測準確度與 R^2 通常更高**，但模型屬於灰黑盒，**可解釋性較低**。

參考來源（NotebookLM 加入的資料）：

- Kaggle 資料集頁面：https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who
- https://github.com/Akshu577/life-expectancy-analysis（回歸與特徵選擇）
- https://github.com/SamruddhiGoswami/LifeExpectancyAnalysis（線性回歸與殘差診斷）
- https://github.com/ranjeetmaurya-git/Life-Expectancy-Analysis-Project（多種回歸模型與 Streamlit）
- https://github.com/NysaSetiawan/LifeExpectancyAnalysis（R Shiny 互動儀表板）

與本作業的比較（本人分析，非 NotebookLM 產生）

面向	網路上常見做法	本作業
缺值、偏態	中位數補值、log 轉換	相同；另外把 `income_composition`、`schooling` 的 0 值視為缺值代碼
特徵選擇	相關矩陣、前向選擇、p 值	比較 5 種方法（含前向選擇 SFS），再以 VIF > 10 剔除共線特徵
重要特徵	教育、收入組成（正向）；成人死亡率、HIV（負向）	結論一致；本作業選出的 7 個特徵中，收入組成、HIV/AIDS、成人死亡率影響最大（教育年數與收入組成高度相關 r = 0.92，資訊重疊，因此未入選）
線性回歸表現	$R^2 \approx 0.85$、RMSE ≈ 3.6 年	全特徵 R^2 0.845、RMSE 3.80；7 特徵 R^2 0.811、RMSE 4.21
資料切分	多為隨機切分	**依國家分組切分**，測試集是 37 個完全沒看過的國家

本作業的 R^2 略低於網路上常見的結果，主要原因是切分方式不同。隨機切分時，同一國家其他年份的資料已經出現在訓練集，模型等於「看過答案」，分數會偏高。本作業以國家分組切分，評估的是模型對**新國家**的預測能力，結果較保守，但更接近真實應用情境。